

## 深度学习和强化学习在自动驾驶中的应用

### 一、导言

道路伤害是世界上造成死亡的主要原因之一。世界卫生组织（WHO）的最新报告显示，每年约有 130 万人死于道路事故（*Be 等人, 2021*）。这一惊人数字的一半以上是弱势道路使用者，即行人、自行车和摩托车。其他研究表明，在所有 VRU 受害者中，行人仍然是大多数受害者（*El Hamdani 等人, 2020 年*）。自动驾驶和辅助驾驶人工智能焦点小组（FG-AI4AD）最近的一项研究强调，道路伤害已经是儿童死亡的主要原因，远远超过艾滋病毒和结核病造成的死亡（*Vellinga 和 O'Kelly, 2021*）。

为了减少道路伤害并应对这些挑战，车辆网络（VANETs）和自动驾驶车辆（AVs）越来越受到学术界和工业界的关注。预计这些技术将有效减少与自动驾驶相关的伤亡，并解决各种长期存在的交通挑战，即道路拥堵、出行延误、停车和安全问题。在 *Singh 等人 (2015 年)* 中，据报告，90% 的车祸估计是人为失误造成的。智能交通系统（ITS）、计算系统和人工智能（AI）的最新进展刺激并为 AVs 的广泛引入铺平了道路。这为智能道路、智能交通安全和旅客舒适度带来了新的机遇。研究人员估计，到 2025 年，将有 800 万辆自动驾驶汽车上路（*Bay 等人, 2021*）。然而，由于过去发生的一些事件，AVs 的普及受到了阻碍。尽管研究人员和汽车制造商仍在研究解决相关问题和剩余挑战的不同方法（*Hussain 和 Zeadally, 2018*）。

自动驾驶汽车能够感知其环境并在无人参与的情况下做出决策，与道路旁基础设施和 VRU 相互合作收集和共享信息（*Lamssaggad 等人, 2021*）。AVs 依靠车辆通信，在发生交通堵塞或事故时交换安全信息、交通状况和警告信息。无人驾驶车辆主要依靠传感器、执行器、复杂算法、人工智能技术和强大的计算资源来运行软件。因此，AVs 能够处理复杂的道路情况，导致以显著提高用户的安全性、舒适性和便利性。

汽车工程师学会（SAE）定义了 6 个级别的驾驶自动化，从全手动到全自动。虽然 0 级和 1 级的特点是没有驾驶辅助，但 2 级的定义是部分驾驶辅助。3 级车辆具有“环境检测”功能，可以在没有人为干预的情况下做出一些明智的决定，例如加速通过缓慢移动的车辆，而在 4 级（高驾驶自动化）中，驾驶员仍然可以选择在系统故障时手动超控。最后，5 级是完全驾驶自动化，在所有情况下都不需要驾驶员（*Ma 等人, 2020 年*）。

为了使 5 级车辆成为可能，它要求车辆具有像人类驾驶员一样的“思考”、“感知”和“反应”能力。人工智能在不同领域的最新成就，特别是在图像分类、目标检测和语音识别方面，已导致越来越多地使用人工智能技术，如深度学习（DL）和强化学习（RL），以实现 5 级车辆。基于 DL 的方法使许多研究能够解决 AVs 中的不同挑战性问题，如准确识别和定位道路上的障碍物、适当的车辆控制和运动规划。

本文试图调查最近用于处理 AVS 主要功能的基于人工智能的技术，即环境感知、运动规划、决策、车辆控制、社会行为和通信。我们的调查仅关注基于 DL 和 RL 的方法，因此省略了基于浅层机器学习（ML）的技术，这是一个在过去进行过广泛研究的主题（*Qayyum 等人, 2019 年; Elasad 等人, 2020 年*）。传统的 ML 方法在实现 AVs 的主要功能（例如环境感知和运动规划）方面显示出其局限性。这促使我们将调查范围局限于 DL 和 RL 方法，以显示它们在实现这些功能方

面的潜力。

DL 和 RL 技术以其改善 AVs 任务的能力而闻名。例如，DL 在目标检测方面表现出了很好的效果，这使得它适合于自动驾驶中的场景理解。RL 已成功应用于其他领域，如游戏和机器人，需要从环境中学习。近年来，由于许多有前途的结果，RL 技术已经引起了 AV 研究界越来越多的兴趣。

审查安排如下。第一节讨论了现有调查，并强调了我们旨在填补当前调查的空白；它还介绍了我们的调查范围和研究方法。第二节简要介绍了应用于 AVs 的 DL 和 RL 方法。第三节介绍了 AVs 的不同传感器。第四节介绍了最近应用于 AVs 的基于 DL 的方法。第五节介绍了旨在解决自动驾驶问题的现有基于 RL 的方法。第六节介绍了开放的研究问题和未来的研究方向。最后，第七节对论文进行了总结。

### 1.1 现有调查

文献中存在多个调查，调查了自主车辆技术的不同方面 (*Ohn Bar 和 Trivedi, 2016; Xue 等人, 2018; Ellassad 等人, 2020; Qayyum 等人, 2019; Hussain 和 Zeadally, 2018; Kuutti 等人, 2022; Rasouli 和 Tsots, 2019; Ma 等人, 2020; Clausmann 等人, 2019; Grigorescu 等人, 2022; Tong 等人, 19; Deb 等人, 2018; Feng 等人, 2020; Ning 等人, 2021; Severino 等人, 2021*)。然而，这些调查中的大多数没有详细讨论人工智能技术的使用，而在自动驾驶车辆的不同应用中，DL 和 RL 的使用较少。*Ohn Bar 和 Trivedi (2016)* 讨论了下一代智能车辆中人类行为的理解、建模和预测，如人与自主车辆内部或周围车辆之间的交互。

*Xue 等人 (2018 年)* 调查了自动驾驶车辆的交通场景理解功能，以及该功能如何帮助事件检测和意图预测。*Ellassad 等人 (2020 年)* 比较了机器学习 (ML) 模型和非 ML 模型之间的估计精度，他们确定了用于评估驾驶行为的 ML 技术的优缺点。*Qayyum 等人 (2019 年)* 讨论了与在车辆网络中应用 ML 相关的挑战，并强调了采用 ML 方法产生的不同安全问题。

*Hussain 和 Zeadally (2018)* 对自动驾驶汽车技术进行了全面回顾，并描述了自动驾驶汽车的设计和 implementation 问题，如自动驾驶汽车行业面临的技术和非技术挑战。此外，他们还介绍了为自主车辆技术优化的 ML 和 DL 的最新发展。然而，这项工作涵盖的 DL 技术很少，仅限于几个方面，即感知、通信和控制，而完全忽略了 RL 技术。

*Kuutti 等人 (2020 年)* 讨论了控制 AVs 的 DL 方法及其在复杂场景中的良好性能。作者介绍了应用于自主车辆控制的现有 DL 方法的优点和局限性。但是，它们没有涵盖自动驾驶的其他主要方面。

*Rasouli 和 Tsotsos (2019)* 根据行人人口统计、交通动力学和环境条件，对不同的行人行为进行了评估。然后，他们研究了分析十字路口行人行为的不同方法。然而，作者没有介绍 DL 和 RL 技术来改善行人和 AV 之间的通信。

*Ma 等人 (2020 年)* 分析了当前使用人工智能技术进行 AVs 的实践，并讨论了与实施相关的挑战和问题。然而，他们并没有关注基于 DL 和 RL 的方法。

*Clausmann 等人 (2019)* 对运动规划技术进行了综述；他们的重点是公路规划。他们讨论了运动规划中的主要算法及其在公路驾驶中的应用。然而，他们没有具体展示 DL 和 RL 在 AVs 领域中的作用。

*Grigorescu 等人 (2020 年)* 研究了自动驾驶中使用的 DL 技术，并强调了该技术在场景感知、路径规划、行为仲裁和运动控制方面的优势和局限性。他们强

调了当前关于自动驾驶 AI 架构设计的主要挑战。

[Tong 等人 \(2019 年\)](#) 讨论了用于车辆到车辆 (V2X) 应用的人工智能方法, 以及这些方法相对于传统算法的性能; 他们也涵盖了人工智能在从不同来源获取信息方面的作用。然而, 他们只关注车对车 (V2V) 和 V2X 中的信息共享问题。

[Deb 等人 \(2018 年\)](#) 回顾了行人与全自动汽车的互动; 他们强调了行人的新行为, 这可能会导致潜在风险, 需要在自动驾驶汽车上路之前进行识别。然而, 他们没有研究 DL 和 RL 方法在实时准确检测行人意图方面的作用。

[Feng 等人 \(2020\)](#) 介绍了应用于自动驾驶的对象检测和分割系统。他们提出了与这些检测方法相关的挑战和开放性问题。

[Arnold 等人 \(2019 年\)](#) 调查了 3D 对象检测方法, 以及 AVs 中常用的传感器和数据集。此外, 作者讨论了基于传感器模式的最新贡献, 并将其分为三大类: 单目、基于点云和融合方法。然而, 本次调查不包括 DL 方法

[Ning 等人 \(2021\)](#) 介绍了用于自动驾驶的现有人工智能架构。他们总结了这些架构的局限性, 并介绍了人工智能 (H-AI) 的概念; H-AI 被认为是未来自动驾驶发展的新视角。它们还提出了未来有待解决的开放性研究挑战。然而, 它们并未涵盖未来可能改善人工智能的基于人工智能的解决方案。[Severino 等人 \(2021\)](#) 讨论了道路标线、十字路口和路面对 AVs 操作的影响, 特别是在驾驶时检测环境。他们还提出了由实施 AVs 系统引起的一些技术问题。(详情见表 1)

## 1.2 当前调查

我们得出结论, 现有调查并未全面涵盖使用 DL 和 RL 技术来解决 AVs 中与场景理解、运动规划、决策、车辆控制、社会行为和通信相关的主要问题。这促使我们填补了文献中的这一空白, 提出了一项新的调查, 致力于迄今为止应用于自动驾驶领域的大量 DL 和 RL 技术。表 1 总结了现有调查的覆盖范围。当前的调查揭示了 DL 和 RL 方法在自动驾驶车辆不同方面的潜力, 并展示了该领域可以实现的目标。与现有的自动驾驶调查不同, 本文是第一篇在 AVs 中实现主要功能时仅关注 DL 和 RL 技术的论文。与其他调查相比, 当前的工作讨论了 DL 和 RL 在自动驾驶中带来的改进, 从而克服了传统 ML 技术的局限性。

## 1.3 本次调查的范围


在本文中, 我们对自主车辆领域应用的人工智能技术的最新研究状况进行了全面调查。我们通过确定 DL 和 RL 技术的优势和局限性, 专门关注它们。此外, 我们还讨论了 DL 和 RL 算法的问题和挑战, 这些问题和挑战需要进一步研究以实现 5 级自治。我们总结了本文的主要贡献如下:

- 1) 概述了 DL 和 RL 技术。
- 2) 我们提出了自动驾驶车辆的详细分类, 包括其组件、设计和实现。
- 3) 我们详细描述了用于解决 AVs 中问题的 DL 和 RL 技术。
- 4) 我们确定了在 AVs 环境下 DL 和 RL 技术的优势和劣势。
- 5) 我们提出并讨论了与 AVs 背景下的 DL 和 RL 技术相关的需要进一步研究的挑战 and 开放问题。

表 1

年份	论文	引用 次数	场景 理解	动态 规划	决策	控制	社会 行为	表达	局限 性	DL 和 RL
2016	Ohn-Bar	174	√	x	x	x	√	x	x	√
2018	Xue	128	√	x	x	√	√	X	x	√
2018	Hussian	230	√	x	x	x	x	√	X	√
2018	Deb	96	x	x	x	x	x	x	X	x
2019	Qayyum	107	x	x	√	x	√	x	v	√
2019	Claussm	93	x	√	x	x	√	X	x	√
2019	Tong	84	x	x	x	x	√	√	√	√
2019	Arnold	70	√	x	x	x	√	√	x	√
2020	Elasad	106	x	√	x	x	X	√	x	x
2020	Rasouli	156	√	√	√	√	√	√	x	x
2020	Kuutti	230	x	√	√	x	√	√	x	√
2020	Ma	117	√	√	x	X	√	X	x	√
2020	Grigorescu	168	√	x	√	√	√	√	x	√
2020	Feng	253	√	x	√	x	x	X	x	√
2021	Ning	154	x	√	X	x	x	x	√	x
2021	Severino	48	x	√	x	x	x	x	√	x

表1



二、深度学习和强化学习的简介

在本节中，我们简要介绍了 AVs 中使用的深度学习技术的基本原理，并展示了每种范式的能力。我们专注于卷积神经网络（CNN）、长短时记忆（LSTM）和



RL，它们是应用于自动驾驶的最常见的 DL 方法。

## 2.1 深度学习

深度神经网络是一种模仿人类智能的连接方法，能够从大量数据中学习。它们有着广泛的应用，从欺诈检测和视觉识别到自动驾驶汽车；然而，它们有着越来越明显的局限性。其中包括易受对抗性示例影响的漏洞，在这些示例中，数据的呈现意图是导致学习到的模型出错。

DL 模型已成功应用于各种自动驾驶应用领域。在过去几年中，它们已成为计算机视觉应用的关键组成部分（见图 1）。神经网络可以解决的关键问题之一是检测和定位图像和视频中的对象，使 AV 能够识别其环境。在目标检测中使用的 DL 方法中有 CNN。它们为 AVs 提供可操作的信息，即检测和分类对象（如车道、交通灯、行人、交叉线和交通标志）。（*Shrestha 和 Mahmood, 2019*）。CNN 在图像分类、目标检测和语义分割方面已显示出良好的效果。它们始终包含三个基本特性，即卷积、池和完全连接层。卷积层由滤波器组成，用于提取图像或视频中的主要视觉特征。这些滤波器将图像的大小转换为小的多阵列，这些阵列馈送到完全连接的层中，输出层预测图像类别（*Gupta 等人, 2021*）。

适合处理数据序列的另一个 DL 模型是 LSTM；神经网络是一种递归神经网络。LSTM 网络使用反馈连接进行序列和模式识别，并使用输入、输出和遗忘门。因此，它记住从上一时间步计算的输出，并根据当前输入提供输出（*Chung 等人, 2014*）。LSTM 网络已应用于不同的自动驾驶任务，如运动规划、决策和车辆控制。因此，这种神经网络（NN）架构能够基于 AVs 的过去动作预测当前动作（*Yu 等人, 2019*）。

DL 的主要优势在于它能够处理来自连接到 AVs 的摄像机的非结构化数据（如图像）。DL 网络可以随着时间的推移从图像和视频的大型示例中学习。在一台计算机上训练这些海量数据可能需要 10 天。然而，鉴于 DL 的性质，GPU 可用于显著减少训练过程。

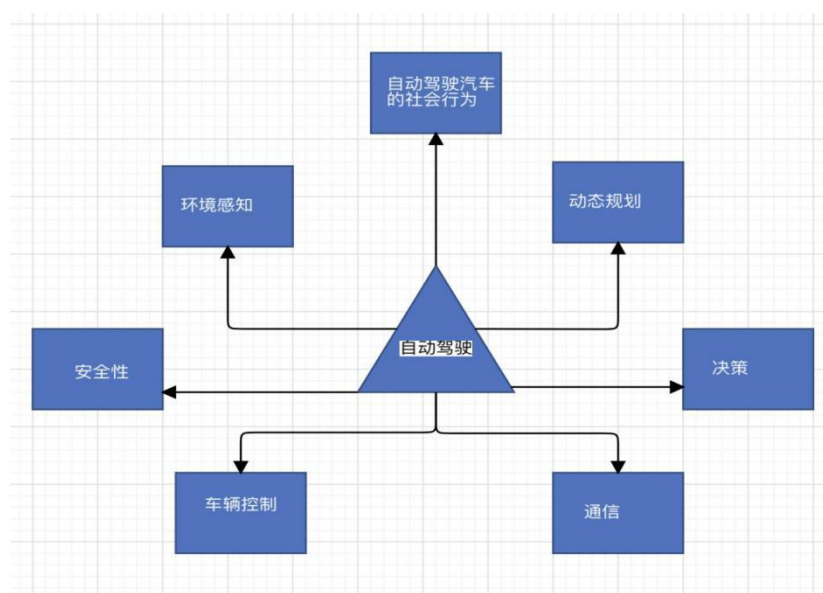


图 1

## 2.2 强化学习

RL 是机器学习的一个子领域，解决了随时间变化的自动学习和最优决策问题。DL 方法专注于开发使用数据进行自主学习的计算机程序，而 RL 方法允许智能代理从错误和经验中学习。RL 代理通过在环境中行动获得奖励；其目标是选择随着时间推移使预期累积回报最大化的行动 (Mousavi 等人, 2016)。

RL 代理可以建模为马尔可夫决策过程 (MDP)，如下所示：代理通过执行动作和接收观察和奖励与环境进行交互。如图 1 所示，在每个时间步骤  $t$ ，代理接收环境状态的一些表示  $s_t \in S$ 。基于此状态，代理选择一个操作  $a_t \in A$ 。选择任何操作都基于代理的行为（也称为策略）。它告诉代理应该为每个可能的状态选择哪些操作。作为每项行动的结果，代理人将获得奖励  $r_t \in R$  并观察下一状态  $s_{t+1} \in S$  (Winder, 2020 年)。我们可以将接受奖励的过程表示为任意函数  $f$ 。在每个时间  $t$ ，我们有：
$$f(s_t, a_t) = r_t$$

RL 的主要目标是找到使每个状态的政策最大化的行动。Q-Learning (Watkins 和 Dayan, 1992) 用于通过学习每个状态-动作对的最佳 Q 值来选择最优策略，从而实现这一目标。Q-Learning 算法使用 Bellman 方程迭代更新每个状态-动作对的 Q 值，直到 Q 函数收敛到最优 Q 函数  $q_*$ ：

$$q_*(s, a) = E \left[ r_{t+1} + \gamma \max_{a'} q_*(s', a') \right]$$

在 Q-Learning 中，行动的选择基于  $\epsilon$  贪婪策略有一个探索率  $\epsilon$  选择随机动作的概率是  $1 - \epsilon$  是选择具有高 Q 值的动作的概率。该 Q 值在每个选定动作中使用给定表达式迭代更新：

$$q(s, a) \leftarrow q(s, a) + \alpha \left[ r + \gamma \max_{a'} q(s', a') - q(s, a) \right]$$

其中  $\gamma$  是反映当前奖励相对于未来奖励重要性的贴现率。 $\alpha$  是学习速率， $s'$  是下一状态。可以看出，Q-Learning 算法的关键是维护一个 Q 表，该表存储状态-动作对的 Q 值。

### 三、自动驾驶车辆

人口增长导致车辆数量增加，对当前交通基础设施（如停车位、充电站和加油站）造成沉重负担。车辆数量的持续增加是交通问题的主要原因，包括空气污染、噪音污染、道路撞车和交通拥堵。为了解决这些问题，研究人员一直在开发 AVs；其目的是消除或至少减少由人工驾驶引起的问题。

AV 被定义为智能代理，可以通过安装在车辆上的不同传感器感知其环境，当人类使用感官（如视觉和听觉）驾驶时，AV 使用传感器（如摄像机和雷达），传感器的质量在构建成功的 AVs 中起着关键作用（见图 2）。例如，如果从相应传感器收集的数据不可靠，则最佳感知算法可能表现不佳。

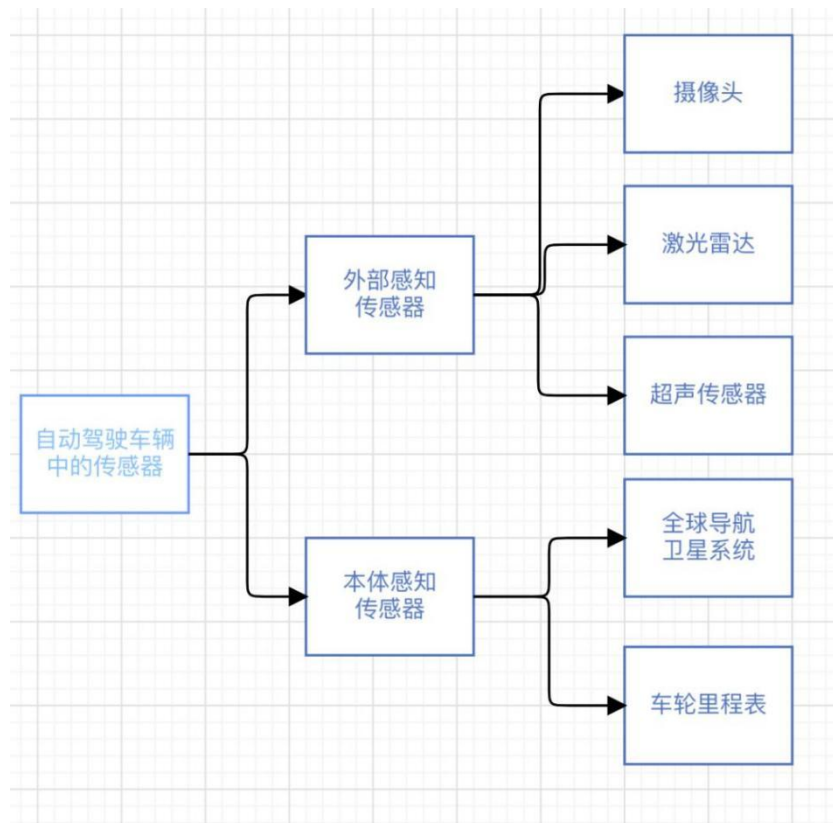


图 2

传感器的作用是测量或检测环境的某些特性或这些特性随时间的变化。传感器大致分为两类：（a）外部感知传感器：它们记录车辆周围环境的特性（例如，摄像机和光探测与测距（LIDAR））；（b）本体感受传感器：它们记录车辆本身的特性（例如，全球导航卫星系统（GNSS）位置和车轮里程表）。

自动驾驶中最常见和最广泛使用的传感器是摄像头。相机是一种被动的采光传感器，可以捕捉场景丰富而详细的信息。摄像机的质量由各种指标决定，如分辨率和视场。分辨率是创建图像并影响其质量的像素数。视场由相机可见的水平和垂直角度范围定义，可以通过镜头选择和变焦来改变。相机的动态范围由图像中最暗和最亮色调之间的差异定义。高动态范围对于自动驾驶车辆至关重要，因为在夜间驾驶时会遇到高度可变的照明条件。具有重叠视场和对齐图像平面的两个摄像机的组合称为立体摄像机；它们生成场景的视差图，用于估计每个像素的深度（*Thakur, 2018*）。

AVs 中的第二个关键传感器是激光雷达。它发射光束。通过测量返回光量和光束的离光时间，可以估计反射物体的折射率。激光雷达生成三维点云地图，用于评估场景几何结构。激光雷达通常由一些关键指标控制，如源的数量、每秒可收集的点以及视场（*Bussemaker, 2014*）。

无线电探测和测距（雷达）传感器的使用时间比激光雷达长。它们能有力地探测到环境中的大型物体，在恶劣天气下尤其有用，因为它们大多不受降雨的影响。雷达传感器的特点是其探测范围、视场以及位置和速度测量精度（*Curry, 2005*）。

超声传感器在 AVs 中也很重要；他们用声波测量距离。它们特别适用于停车场景，其中车辆需要移动得非常靠近其他车辆（*Curry, 2005*）。

车辆工业中的主要本体感知传感器之一是全球导航卫星系统，如 GPS 或伽利略。全球导航卫星系统允许测量车辆位置、速度，有时还可以测量航向。惯性测量单元（IMU）测量车辆的角转速和加速度。另一个重要的本体感觉传感器是车轮里程表；它跟踪车轮转速，并使用此信息估计车辆的速度和航向变化率（Reinholtz 等人，2007 年）。

一般来说，在识别环境后，AV 执行许多任务，包括目标检测、规划、决策、控制速度和驾驶，而无需任何人工干预。

四、基于 DL 的自动驾驶方法

在本节中，基于现有的 DL 的方法，我们调查了用于解决 AVs 的主要任务，即（1）环境感知 （2）运动规划，（3）决策，（4）车辆控制，（5）自动驾驶汽车的社会行为，（6）通信。（见图 3）

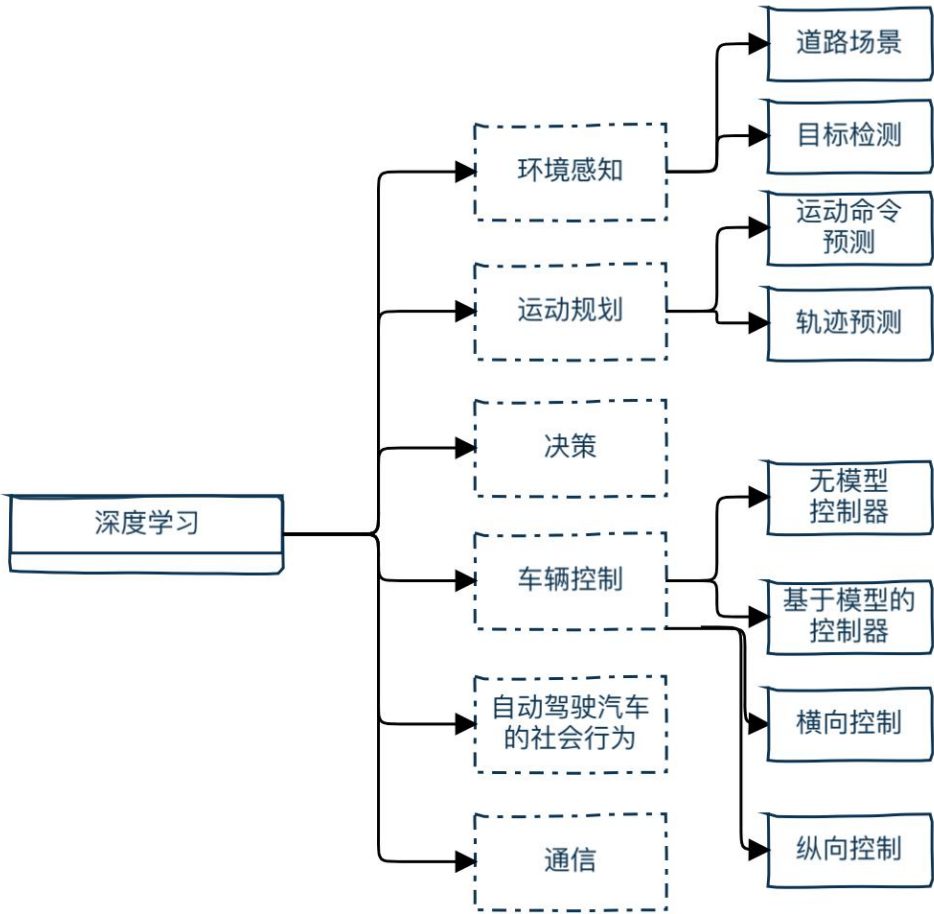


图 3

4.1 环境感知

在过去二十年中，环境感知领域使用有效的 DL 技术取得了重大进展。这一进展使 AVs 能够通过使用不同的传感器（如激光雷达、摄像机和雷达）提供有关驾驶环境的关键和精确信息。事实上，深度 CNN 在实时图像分类和检测方面已显示出显著的结果。在环境感知中使用 DL 技术为 AVs 提供了可操作的信息，如车



道、交通灯、行人、交叉线、交通标志等的检测（见图 4）。

尽管如此，对于车辆来说，感知仍然是识别道路几何形状以及识别道路上的物体比如行人、自行车和其他车辆的主要先决条件之一。感知可以分成两个部分：道路场景和目标检测。

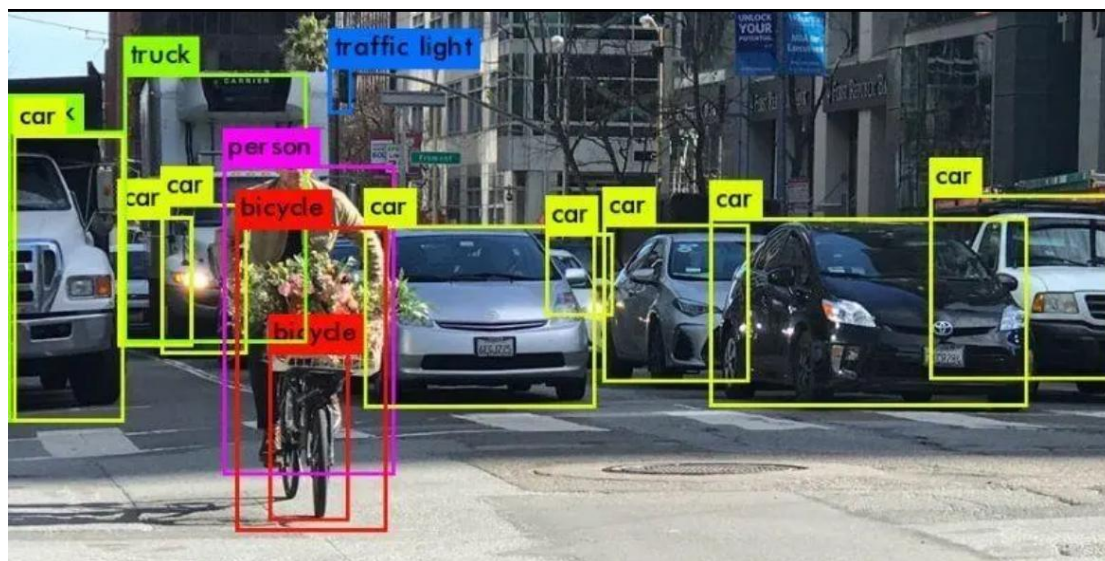


图 4

#### 4.1.1 道路场景

准确识别和提取主要道路信息对于 AVs 识别道路要素（如路面、沟渠、护栏和围栏）至关重要。而 DL 的强大功能可以实现高精度的道路要素识别。例如，[Balado 等人 \(2019 年\)](#) 使用移动激光扫描 (MLS) 获得的信息来识别道路环境的主要元素。他们的提议基于 Point-net ([Qi 等人, 2017](#)) 和语义分割 (SS) 方法来识别道路元素，它为城市地区的 AVs 提供了良好的视野。

识别道路的几何结构为 AVs 提供了有关其环境的更多信息。[Laddha 等人 \(2016 年\)](#) 使用基于监督和非监督学习的混合算法，使用 CNN 识别道路几何形状，尽管该算法减少了人为标注的工作量，使训练更具可扩展性，但仍需要在不同情况下以及关键天气条件下对其进行评估。

全面了解周围环境和道路面积（例如遮挡、3D 几何和道路拓扑类型）有助于在自动驾驶中的实际应用。为此，[Yan 等人 \(2020 年\)](#) 开发了一种基于激光雷达数据的多任务道路感知网络 (LMRoad-Net) 方法。LMRoad-Net 旨在检测和估计道路测量值，如道路长度和形状，以识别其拓扑结构。

道路转角被认为是识别的挑战性区域之一，[Bolte 等人 \(2019 年\)](#) 的一项研究引入了道路转角的正式定义，并做到在 AVs 摄像机的视频信号中检测到它们。因此，基于 CNNs 的系统使 AVs 能够在危急情况下感知更好的道路。

[Tümen 和 Ergen \(2020\)](#) 开发了一种图像处理方法和基于 DL 的方法，使用 CNN 检测公路上的交叉口、分隔和人行横道。鉴于这些地方事故发生率高，此类检测对于改善道路安全至关重要。

[Di 等人 \(2017 年\)](#) 研究了交通场景下的问题，以从具有照明条件的图像中识别道路对象。他们考虑了基于 CNN 的密集对应迁移学习方法，以提取城市环境图像的深度表示。然而，这种方法没有考虑到不同和复杂的驾驶场景。

交通标志的成功检测和分类是全自动驾驶汽车要克服的主要挑战之一。例如，

[Sajjad 等人 \(2020 年\)](#) 开发了一种检测和避免障碍物的方法。该模型基于视觉传感器识别各种交通标志，它允许使用超声波传感器避开障碍物。作者实现了他们的原型，通过仅使用单目视觉传感器来促进车辆感知。

#### 4.1.2 目标检测

准确、实时地检测周围物体，包括其他道路使用者，对于 AVs 至关重要。[Wang 等人 \(2020b\)](#) 提出了一种基于 DL 技术的端到端的 3D 对象检测方法。具体而言，他们的技术使用 CNN 和融合网络 (FoFNet) 来预测车辆、行人和自行车等物体的边界框和类别。

[Prabhakar 等人 \(2017 年\)](#) 提出了一种通过考虑天气条件来提高检测效率的方法。更具体地说，他们使用区域卷积神经网络 (R-CNN) 来识别和分类障碍物，如车辆、行人和动物。在雨天，他们在每个检测到的对象顶部使用带有类名的边界框。然而，需要对其他道路图像数据集进行更多测试，以评估该模型的准确性和适用性。

除了目标检测，还需要估计其他关键参数 (例如距离) 来帮助实现自动驾驶。[Chen 等人 \(2018b\)](#) 提出了多任务组合策略 (CP-MTL) 算法，该算法旨在通过在检测期间估计车辆与其他道路用户之间的距离来改进检测。

[Li 等人 \(2021\)](#) 解决了夜间使用 CNN 进行检测的问题，以改进微光图像识别。他们认为他们的提案可以帮助 AVs 识别道路，特别是在没有路灯的农村地区。

[Dinh 等人 \(2020 年\)](#) 提出了一种基于 CNN 的方法，用于更好地检测城市交通中的目标。他们假设 AVs 配备了两个焦距不同的摄像机，表明方案允许检测小型物体 (例如，小型和远处的车辆)。

现有的几种方法 ([Wang 等人, 2020b](#); [Prabhakar 等人, 2017](#); [Chen 等人, 2018b](#); [Li 等人, 2021](#); [Dinh 等人, 2020](#)) 依赖视频进行目标检测，随着时间的推移，它们在连续帧中对对象进行分类。然而，这没有考虑图像帧之间的空间和时间相关性，从而导致信息丢失。为了填补这一空白，[Liu 等人 \(2020 年\)](#) 基于运动辅助特征校准网络 (MFCN) 确定了两种情况下的车辆，即遮挡和截断。与 [Ren 等人 \(2017\)](#)、[Song 等人 \(2018b\)](#) 和 [Zhang 等人 \(2017\)](#) 相比，他们的提案 ([Liu, 2020](#)) 的评估确实显示了在不同物体外观下更好的检测精度。

由于来自传感器的大量数据，减少训练期间的数据量可以提高检测模型的性能。基本上，仅使用重要数据可以缩短基于 DL 的方法的训练时间。驾驶过程中的时间至关重要，尤其是在紧急情况下；因此，检测必须是实时的 ([Das 等人, 2020 年](#))。

3D 物体检测可显示更精确的物体大小和位置信息，以实现自动驾驶。自动驾驶的许多重要方面，如运动规划和车辆控制，通常需要车辆周围的 3D 空间的真实表示。现有的 3D 对象检测贡献在使用传感器进行检测的方式上有很大的不同。一些贡献 ([Ma 等人, 2019 年](#); [Peng 等人, 2020 年](#)) 仅使用单目相机。例如，[Zhang 等人 \(2020b\)](#) 提出了一种新的单目框架，用于自动驾驶环境中的三维检测，目标是使用 3D 盒子检测和定位对象。

许多其他的方法提出要融合相机图像和激光雷达数据，[Chen 等人 \(2017a\)](#) 试图通过开发基于多视图 3D 网络 (MV3D) 的 3D 对象检测方法来提高检测性能。他们的方案使用激光雷达点云和 RGB 图像来预测 3D 边界框，它的性能超过了仅依靠传感器的方法。[Hong 等人 \(2020 年\)](#) 提出了一种 3D 检测方法，利用激光雷达点云和 RGB 图像作为交叉融合网络方法的输入。他们通过模拟表明他们的提议

允许检测通常仅使用传感器难以检测的对象。

弱势道路使用者的安全仍然是主要的挑战性问题之一。因此，行人的检测是最重要的。在此背景下，[Zhao 等人 \(2020 年\)](#) 提出了一种基于内部级联网络 (InCNet) 的称为行人位置感知网络 (P-LPN) 的方法。P-LPN 将行人分为两类：在车道上行驶的行人和在人行道上行驶的人。它使用区域建议网络 (RPN) 在语义地图上提供每个行人的位置。然而，P-LPN 没有考虑行人的意图，这对于 AVs 了解行人的运动非常重要。

根据已审查的工作，可以公平地得出结论，检测和识别在准确性和检测延迟方面已达到相当高的可靠性水平，特别是当涉及两个或多个传感器模式的融合时。其中一些方法侧重于识别交通标志、道路结构等。其他方法解决了实时检测拐角和交叉口道路用户的问题。例如，[Zhao 等人 \(2020 年\)](#) 研究了车道和人行道上行人的检测。然而，这种方法需要更多细节来具体识别行人在车道上移动的每个区域，这可能会提高检测精度。而且大多数方法未考虑天气和光照条件。因此，今后的工作应进一步调查这些问题。（文献详情见下表 2）

表 2

年份	论文	输入	数据集	方法	神经网络	DL 框架	交通	天气	光照
2016	Laddha	相机	KITTI	MSD	CNN	Keras	Urban	X	X
2017	Di	相机	1130img	DCTL	CNN	Caffe	Highway	✓	✓
2017	Prabaka	相机	KITTI iRoads...	ODA	R-CNN	Tensorflow	Urban	✓	✓
2017	Chen	LIDAR	KITTI	Classic	CNN	MXNET	Urban	X	X
2018	Balado	相机	KITTI	MV3D	CNN	X	Urban	X	X
2019	Bolt	MLS	113.6mpVc	MTL	PointNet	X	Urban	X	X
2019	Zhao	相机	Cityscapes	SS	CNN	Tensorflow	Urban	X	X
2020	Das	相机	Cityscapes	TCCD	RPN	Keras	Urban	X	X
2020	Wang	LIDAR	Camvid	P-LPN	CNN FoFNet	X	Urban	X	X
2020	Sajjd	相机	KITTI	3D	DNN	X	Urban	X	X
2020	Liu	相机	836img	DTS	CNN	X	Urban	X	X
2020	Tumen	相机	KITTI	MFCN	CNN	X	Urban	X	X
2020	Hong	LIDAR	KITTI	ICD	CNN R-FCN		Highway	X	X
2002	Zhang	相机	KITTI	CN	CNN	X	Urban	X	X
2020	Zhao	相机	KITTI	MCK-N ET	CNN	X	Urban	X	X
2020	Dinh	相机	1wimg	VD	CNN	Tensorflow	Urban	X	X
2020	Yan	LIDAR	MultiRoad	LMRoadNet	CNN	X	Urban	X	X
2021	Li	相机	BDD100k	LE-Net	CNN	X	Urban& Rural	X	✓



## 4.2 运动规划

在环境感知之后，运动规划是 AVs 的下一个主要任务，通过避免在不同环境中发生碰撞来安全平稳地导航。为了处理运动规划问题，传统方法（例如 Dijkstra 算法、A-Star 算法和 State lattice 算法）依赖于优化模型，这些算法在大范围内速度较慢，因此不适合实时应用。因此，许多研究人员提出了替代方法，如基于深度学习的技术。这些方法分析感知信息，以便识别障碍，然后预测正确的动作。这使得 AVs 能够在时间和距离方面找到有效的路径，从而安全导航。

我们将运动规划分为两类：运动需求预测和轨迹预测。运动需求预测主要包括计算转向角、加速度和/或制动，而轨迹预测包括计算所有道路参与者（包括 ego 车辆）的短期轨迹及其未来状态。

### 4.2.1 运动命令预测

由于交通状况的复杂性，很难构建通用的运动规划系统，尤其是实时的。事实上，道路使用者的行为仍然不可预测，难以建模。例如，[Bai 等人 \(2018 年\)](#) 结合 CNN 和 LSTM 提取时空信息，目的是基于真实数据实时预测转向角。[Song 等人 \(2018a\)](#) 使用从驾驶模拟器收集的数据，使用类似的方法估计转向角。

[Chen 等人 \(2018a\)](#) 提议将 CNN 和 LSTM 结合起来，以做出规划决策。他们报告说，使用模拟和真实交通可以让 AVs 在许多情况下更好地模拟人类驾驶情况。然而，我们认为，应更广泛地测试他们的提案，以评估和改进其性能。

一些贡献 ([Bai 等人, 2018 年](#); [Song 等人, 2018a](#); [Chen 等人, 2018a](#)) 确实只关注转向角估计，其他人则用一个以上的动作命令来处理。例如，[Hu 等人 \(2020 年\)](#) 提出了一种基于 CNN 和 LSTM 的深度级联神经网络，以同时预测多个运动指令（即转向角、加速度和制动）。

### 4.2.2 轨迹预测

AVs 需要分析传感器收集的数据以检测障碍物，从而安全导航到目的地。[Zhao 等人 \(2019 年\)](#) 提出了学习卡尔曼网络 (LKN)，以根据相机使用深度学习收集的数据估计车辆的轨迹。[Banzhaf 等人 \(2019 年\)](#) 提出了一种基于 CNNs 的方法，该方法使用收集的数据预测车辆的未来运动，同时考虑静态障碍物和非结构化道路。因此，在他们的提案中使用了双向 RRT 以减少计算时间。

[Grigorescu 等人 \(2019 年\)](#) 提出了一种改进 AVs 最佳路径轨迹预测的方法，他们融合激光雷达和雷达数据来估计最佳轨迹。[Cui 等人 \(2019\)](#) 提出了一种估计其他车辆和行人轨迹的方法，他们使用 CNN 处理来自激光雷达或雷达的数据。[Djuric 等人 \(2020 年\)](#) 使用类似的方法预测短期车辆轨迹和道路参与者（如周围车辆）的未来状态。[Deo 和 Trivedi \(2018\)](#) 提出了 CNN 和 LSTM，以预测各种交通场景中周围车辆的未来轨迹。[Zhang 等人 \(2020c\)](#) 通过探索人类驾驶员在环境中的经验特征，使用模仿学习 (IL)，他们利用 CNN 处理 3D 环境信息，并提供周围车辆的状态。

[Leordeanu 和 Paraicu \(2021\)](#) 开发了一种方法，仅基于视频和最终目的地预测 AVs 的当前位置和未来轨迹，该方法能够适应不同天气条件下的短期和长期导航。

[Jeong 等人 \(2020 年\)](#) 提出了一种基于 LSTM 和 RNN 的运动预测算法，目标是减少交叉口的交通事故。该算法以环绕车辆的状态信息为输入，预测目标状态



序列。

[Rehder 等人 \(2018 年\)](#) 使用完全卷积网络 (FCNs) 操作环境地图, 以推断所有可能的行人目的地。仿真结果表明, 该系统能够准确预测目的地和轨迹。(文献详情见表 3)

表 3

年份	论文	输入	数据集	输出	神经网络	DL 框架	实验	模拟
2018	Song	相机	8HDD	Steering	CNN LSTM	Caffe	Simulation	ET
2018	Bai	相机	80G RID	Steering	CNN LSTM	Keras	Real	-
2018	Rehder	相机	Real world	Pedsetrian	CNN RMDN	NP	Real	-
2018	Chen	相机	Simulation	Steering	CNN LSTM	NR	Simulation	GTA5
2019	Deo	相机	NGSimulati on	Steering	LSTM	PyTorch	Real	-
2019	Cui	相机 LINDAR RANDAR	240h RGB Img	Future Trajectories Of AVs	CS-LSTM	Tensor Flow	Real	-
2019	Grigore	LINDAR RANDAR	50kn HW	Trajectories Of AVs	CNN	NP	Real	-
2019	Banzahf	LINDAR	13418TTS	Trajectories Of AVs	CNN LSTM	Tensor Flow	Simulation	Gazebo
2020	Zhao	相机	KITTI	Steering	CNN	Caffe	Real	-
2020	Zhang	相机 LINDAR	NGSimulati on	Trajectories Of AVs	CNN LSTM	Tensor Flow	Real	-
2002	Hu	相机	ImgNet	Steering	CNN		Simulation	ET
2020	Djuric	相机	240h Avs	Steering	CNN	TF	Real	-
2020	Jeong	相机 LINDAR	4312TVD	Target state of AVs	CNN LSTM	X	Real	-
2020	Leordeanu	相机	UED	Current location	CNN LSTM	X	Real	-

### 4.3 决策

自动驾驶中的决策需要准确、充分地反映环境, 以前的方法使用传统方法(如启发式和数值优化), 但未能模拟所有可能的情况, 深度学习技术最近已显示出其在实时和复杂环境中做出决策的能力。

[Li 等人 \(2018 年\)](#) 通过提取道路场景图像, 使用 CNN 模拟人类驾驶员, 以做出正确的驾驶决策。[Gallardo 等人 \(2017 年\)](#) 在 [Krizhevsky 等人 \(2012 年\)](#) 中提出了一种通过使用 CNN 特别是 AlexNet 架构的环境为自动驾驶车辆做出决策

的方法。[Xie 等人 \(2019 年\)](#) 提出了一种使用 LSTM 的车道变换方法，以模拟和周围车辆之间的相互作用。

车道变换机动仍然是车辆自动驾驶系统的一项复杂而富有挑战性的任务，因此，有必要开发能够在考虑周围车辆运动的情况下进行车道变更的精确系统。[Liu 等人 \(2019b\)](#) 提出了一种基于 DNN 的方法，该方法受益于驾驶员的历史经验和 V2V 信息，从而实现精确的换道操纵。

[Strickland 等人 \(2018 年\)](#) 提出了一种在紧急情况下避免碰撞的方法，为此，他们使用贝叶斯卷积 LSTM 处理数据并避免现有冲突。[Wang 等人 \(2020c\)](#) 使用 R-CNNs 引导环形交叉口处的自动驾驶车辆，当自动驾驶车辆到达环形交叉口时，他们的专业人员能够做出决定（例如，进入或等待）。

#### 4.4 车辆控制

车辆控制负责纠正运动规划和决策任务产生的错误，AVs 中控制器的作用是稳定和引导车辆沿路径行驶，它接收由感知和定位模块估计的车辆状态。基于这些状态，AVs 选择合适的控制命令。

在本小节中，我们首先介绍了允许最小化成本函数  $\kappa = f(\mathbf{x}(t), \mathbf{u}(t))$ ，它是在一组状态  $\mathbf{x}(t)$  和控制动作  $\mathbf{u}(t)$  上定义的，这些传统控制器可分为无模型控制器和基于模型控制器。

**无模型控制器：**这种控制器不使用被控制系统的任何数学模型，它们允许根据设定点和当前状态之间的误差校正动作。这些控制器易于实现，因为它们不需要深入了解系统行为。然而它们很难调整，不能保证最佳性能，只能在有限的操作条件下正常工作 ([Samak 等人, 2011](#))。这种控制器的一个例子是比例积分微分 (PID)，它允许 AVs 以尽可能小的振动或抖动达到其目标状态。PID 的输出取决于三个超参数，每个超参数对应于控制器缩写 (P-I-D)，这些超参数特定于每种应用 ([Kiong 等人, 1999 年](#); [Crenganis 和 Bologa, 2016 年](#))。

[Farag \(2020\)](#) 使用 PID 控制器在路径规划器计算的整个轨迹上操纵飞行器，测试结果显示了 PID 在不同车速下的性能。[Alonso 等人 \(2013 年\)](#) 提出了一种基于二次函数最小化的 PID 控制器参数调整方法，他们的建议适用于控制一辆自动驾驶汽车跟随前面的另一辆车。

**基于模型的控制器：**这些控制器使用数学模型来控制被控制的系统，运动学控制器确定车辆的运动，忽略作用在系统上的内力或外力。当加速度不显著时，它们特别在低速时有效。[Satouri 等人 \(2021\)](#) 使用了运动学模型的示例，例如自行车模型 ([Rajamani, 2011](#))，该模型允许控制非线性车辆的运动。该模型估计了飞行器的速度和转向角，以及前后轮胎的转弯刚度。使用 CarSim 模拟器对其方案进行了测试和验证；结果显示了他们的模型跟踪运动规划给定的参考路径轨迹的性能。

动态控制器考虑作用在系统上的力和扭矩，以估计车辆的运动。模型预测控制使用系统的线性或非线性运动模型来预测其未来状态，并通过在每个时间步解决优化问题来确定最优控制行为 ([Samak 等人, 2011](#))。

[Funke 等人 \(2016 年\)](#) 将模型预测和反馈控制器相结合，以估计到达所需目的地所需的转向角，同时保持稳定性并避免碰撞。

[Li 等人 \(2017 年\)](#) 提出了一种方法，允许控制 AV 跟踪参考路径并避免碰撞（例如，车辆、骑自行车的人和行人）。他们的提案结合了前馈和反馈控制器 ([Kapania 和 Gerdes, 2015](#))，以在驾驶时调整转向角。[Ni 等人 \(2017 年\)](#) 还

使用前馈和反馈控制器沿所需路径引导 AV，他们的模型估计轮胎转弯刚度，以增强控制器的鲁棒性。

以前的控制器需要深入了解过程和调整，此外，在实现合适的控制器之前，需要知道运动学或动力学模型。这些控制器用于特定场景，不适用于其他情况。当场景发生变化时，需要重新调整它们。另外，它们没有考虑每个道路使用者的运动，例如其他车辆、骑自行车者和行人。因此，在设计新的自动驾驶车辆相关方法时，一般考虑 VRU，特别是行人专用区变得至关重要。这将有助于更好地理解并预测 AVs 上路时行人的意图。

值得注意的是，这些控制器不处理复杂的情况，如交通拥挤、交叉口、人行横道等。它们只专注于控制 AVs 遵循运动规划生成的参考路径。由于这些原因，人工智能技术，特别是 DL 和 RL，通过从环境中学习以获得精确的控制要求（如转向和调节速度），优于这些传统技术。

控制系统分为两类：（a）纵向控制：调节车辆巡航速度；（b）横向控制：操纵车轮进行路径跟踪。

#### 4.4.1. 横向控制

横向控制：允许选择所需的转向角并校正行驶过程中可能累积的任何错误。

[Rausch 等人 \(2017 年\)](#) 提出了一种基于 CNN 的预测转向角的方法。他们从 AVs 摄像机收集的数据训练他们的提案，该方法已在只有双车道道路且无交通的情况下进行了评估。

[Sharma 等人 \(2018 年\)](#) 提出了一种在不同轨道（例如，多车道轨道和单车道未知轨道）中引导 AVs 的方法。他们使用 CNN 和 TORC ([Wymann 等人, 2000 年](#)) 利用从传感器收集的数据（即速度、转向角、油门和制动位置）来训练和测试他们的提案。仿真结果表明，他们的模型能够成功地控制车辆，并在不越过车道线的情况下完成整个圈。然而，他们的方法仅在 TORCS 模拟器的两个轨道上进行模拟。

[Lee 和 Ha \(2020\)](#) 结合 CNNs 和 LSTM 来估计 AVs 的转向角，CNN 用于在驾驶过程中从摄像机图像中提取特征，这些特征被馈送到 LSTM 以估计转向角。

[Maqueda 等人 \(2018 年\)](#) 解决了在不同白天（如太阳和夜间）估计转向角的问题。他们利用 [He 等人 \(2016 年\)](#) 中使用的 CNN 来训练来自事件摄像机的数据 ([Lichtsteiner 等人, 2008 年](#))。模拟结果表明，他们使用事件摄像机的方案在不同条件下（快速运动、挑战性照明）具有性能。

[Yang 等人 \(2018b\)](#) 报告说，仅预测转向角不足以进行车辆控制，因此他们建议包括速度控制的估计。他们使用具有 5 个卷积层和 4 个完全连接层的 CNN 从 Udacity 模拟器（公共驾驶数据集，2017）的数据中提取特征。他们使用的训练数据集包括速度值、转向角度和来自三个前视摄像头的视频流。提取的特征被馈送到 LSTM 以预测转向角和速度指令。

[Chen 等人 \(2019c\)](#) 提出了辅助任务网络 (ATN) 方法，使用 [Bojarski 等人 \(2016\)](#) 中的 CNN 和 LSTM 来学习驾驶车辆。他们训练他们的网络结构，根据摄像机的图像输入预测转向角。他们使用 Udacity 模拟器和人工智能数据集评估了他们的提案。

[Mújica Vargas 等人 \(2016 年\)](#) 研究了一种增强型司机混合方法，以在不同情况下（例如，车道变更、交通灯、交通标志以及从一条道路切换到另一条道路）驾驶 AVs，他们的提议将 CNN 和 RNN 结合起来，CNN 从 Udacity 模拟器中提

取数据的特征。然而，它们没有考虑到障碍物和其他道路使用者。

[Kebria 等人 \(2019 年\)](#) 提出了一种基于 CNNs 的架构，以减少训练时间并预测 AVs 的转向角。他们使用 CNN 在驾驶过程中提取记录图像的重要特征。他们得出结论，在第一层具有较大滤波器的 CNN 架构具有出色的性能。

[Yang 等人 \(2018a\)](#) 使用 TORCS ([Wymann 等人, 2000 年](#)) 和 CARLA ([Dosovitskiy 等人, 2017 年](#)) 模拟器进行数据收集，而不是包括不同的条件（例如白天和晚上）。该数据被馈送到 CNN 以估计 AVs 的转向角。然而，作者没有考虑其他具有挑战性的场景（如交叉口和密集交通）。

#### 4.4.2. 纵向控制

纵向控制：它负责自动引导，通过在驾驶过程中调节 AVs 的速度来确保安全和舒适。DL 已成为纵向控制中的一种流行方法，因为它可以基于在真实世界或仿真环境中收集的标记训练数据来估计正确的速度。

[Mohseni 等人 \(2018 年\)](#) 提出了一种模型预测控制（MPC）方法，用于调节 AVs 的速度以避免障碍物。他们利用从每个检测到的障碍物的激光雷达传感器收集的数据（包括位置、大小和速度信息）来训练 DNN 架构。他们提案的目的是定制障碍物出现的速度。

[Szilassy 等人 \(2019 年\)](#) 提出了一种控制方法，使用 DNN 估计交叉口 AVs 的速度。DNN 将 AVs 的位置和初始速度作为输入。然而，他们的提案没有考虑交叉口的其他关键参数（例如行人行为）。

[Al-Sharman 等人 \(2020 年\)](#) 提出了一种基于 DNN 架构的状态估计方法。他们使用真实的车辆来模拟人类驾驶员收集数据（车辆状态、动力状态和制动值），将数据输入 DNN 以预测制动压力。

#### 4.4.3. 横向和纵向控制

横向和纵向控制：前面的章节表明，DNN 可以进行车辆纵向或横向控制的培训。为了改善转向和加速机制，可以同时使用纵向和横向控制。在下文中，我们将简要讨论使用这两种控件的方法。

[Chen 等人 \(2015\)](#) 提出了一种估计控制命令（转向、加速和制动）的方法。他们使用 TORCS (2021) 收集的 12 小时视频数据训练 CNN。他们的提议使 AVs 能够在不同的场景中驾驶。[Devineau 等人 \(2018 年\)](#) 提出了一种多层感知（MLP）方法，使用 CNN 训练 AVs 在具有挑战性的情况下驾驶（包括在长直线和窄曲线之间移动）。结果表明，他们的建议在估计转向角方面是有效的。

[Sharma 等人 \(2019\)](#) 使用 TORCS (2021) 收集数据（包括按速度、转向角、油门和制动位置标记的道路图像）。这些数据被输入到 CNN，用于训练他们同时学习预测车速和转向角。

[Xing 等人 \(2020 年\)](#) 开发了一种在公路上产生车道变化的方法，虽然该方案在培训阶段同时使用了 CNN 和 RNN，但尚未在流量密集的关键情况下进行测试。（文献详情见表 4）



表 4

年份	论文	输入 •	数据集	输出	神经网络	控制系统	实验	模拟
2015	Chen	相机 LINDAR	KITTI	Steering Acceleration	CNN	Lateral	Real Simulation	TORCS
2017	Rausch	相机	CARSimulation	Steering	CNN	Lateral	-	-
2018	Mohseni	相机	-	CV	FCN	Longitudinal	Real	-
2018	Yang	LINDAR	Udacity	Steering	CNN LSTM	Lateral Longitudinal	Simulation Real	TORCS
2018	Yang	相机	Comma	Steering	GAN	Lateral	Real	-
2018	Sharma	相机	10h of driving data	Steering angle	CNN	Lateral	Simulation	9Dof
2018	Maqueda	相机	9Dof	Steering	CNN	Lateral	-	-
2019	Szalissy	DAVIS	DAVIS	Steering	CNN	Lateral	Simulation	Udacity
2019	Kebria	-	-	Acceleration	NN	Lateral	Simulation	Udacity
2019	Chen	14412img	14412img	Steering	CNN	Lateral	Simulation	Udacity
2019	Sharma	相机	Comma	Steering	CNN	Lateral	Simulation	Udacity
2020	Xing	相机	TORCS	Lane	RNN LSTM	Lateral Longitudinal	Real	-
2020	Sharma	Can bus	DC	Brake	DNN	Longitudinal	Real	-
2020	Lee	相机	600GB img	Steering angle	CNN LSTM	Lateral	Simulation	Euro truck
2020	Mujica	相机	UData	Steering	CNN RNN	Lateral	Simulation	Udacity

#### 4.5 自动驾驶汽车的社会行为

汽车行业的目标是在未来几年引入五级（全自动化）AVs，在未来的交通系统中获得完全的 AVs 将取决于 AVs 如何识别道路使用者的行为。深度学习技术在理解道路使用者的意图从而及时做出交通决策方面确实显示出了有希望的结果。

许多技术已被广泛用于了解行人在道路上的行为，无论是通过了解行人运动还是分析行人行为和意图。[Hoermann 等人（2018 年）](#)将贝叶斯过滤技术和 CNN 结合起来，对道路用户（包括行人、自行车和车辆）进行数据训练，他们提案的目的是估计每个道路使用者的意向。

[Saleh 等人（2020 年）](#)提出了在交通环境中理解行人意图的问题。仅基于摄像头的视频，他们使用 [Huang 等人（2017）](#)的 DenseNets 实时检测和跟踪行人，提出的方法在意图预测方面显示了有希望的结果。

[Abughalieh 和 Alawneh（2020）](#)提出了一种基于 CNN 和收集的图像来预测行人意图的方法。他们的建议允许在人行横道中识别行人方向和 AVs 的距离。然而，他们并不实时考虑行人的姿势。

[Morales Alvarez 等人（2020 年）](#)使用 AVs 中传感器获取的数据来识别行人位置（例如姿势和位置）。他们利用这些信息基于 RNN 估计行人的交叉意图。他们的结果表明，75%的测试在意图预测方面是成功的。

*Muscho11 等人 (2020 年)* 使用贝叶斯网络来了解行人过街时的行为。结果表明, 他们的提案比其他现有方法更好地估计行人位置 (*Gupta 等人, 2018 年; Huang 等人, 2019a; Mohamed 等人, 2020 年*)。

*Poibrenski 等人 (2020 年)* 使用 RNN 估计道路上每个行人的所有可能位置, 训练该网络以基于从车辆摄像机收集的图像预测行人位置。

*Elallid 等人 (2022 年)* 提出了一种模型, 使用 P-LPN 技术检测和统计避难岛上的行人。数字随时间更新, 并使用 LSTM 预测自动驾驶车辆的决策。这个决定取决于等待过马路的行人数量。如果行人数量较多, 自动驾驶车辆需要制动, 以便给行人提供穿越的机会, 否则自动驾驶车辆会加速。

#### 4.6. 通信

通信技术对提高自动驾驶车辆的感知和规划能力以及实现更好的车辆控制具有有效的影响, 在某些情况下, 传感器无法向 AVs 提供准确的信息。在这些情况下, 通信可用于在车辆之间共享信息。

信道状态信息 (CSI) 是无线通信中用来描述通信链路信道参数的术语, 该信息表示散射、衰落和功率随距离衰减的累积效应, 并描述信号如何从发射器传播到接收器。

*Du 等人 (2017 年)* 提出了一种 LSTM 方法来解决大面积的资源分配问题, 他们收集了 24 小时的数据并进行了标记。根据历史交通数据, 他们的建议允许检查一段时间内的交通量。

*Li 等人 (2019b)* 建议通过在车辆和基础设施之间实时共享数据来提高 V2I 通信的可靠性, 他们使用 DNN 来加速处理如此大量的数据。测试结果表明, 该方法在密集交通中具有良好的性能。

*Gao 等人 (2019 年)* 提出了一种解决 V2X 通信功率分配问题的方法, 他们使用 DNN 实时提供资源分配解决方案。*Chen 等人 (2019b)* 利用 CNN 来训练来自 V2I 和 V2V 通信的数据, 解决了同样的问题。他们得出结论, 与 DNN 架构相比, CNN 减少了网络的权重, 从而加快了训练过程。

*Liu 等人 (2019a)* 使用 LSTM 对数据 (包括历史 CSI) 进行训练, 以预测未来 CSI, 用于管理资源分配。他们对数据进行归一化, 以加速网络权重的优化, 并快速找到最优解。结果在信道预测方面优于 Xu 等人 (2019) 的方法。

*Zhang 等人 (2020d)* 使用 DNN 处理 GPS 数据, 即每辆车的时间戳、纬度和经度信息。该数据被馈送到 DNN 以预测 CSI。

#### 五、基于 RL 的自动驾驶方法

尽管 DL 技术在 AVs 中取得了很好的效果, 但它们仍远不能确保 AVs 的完全自主性, 尤其是在决策、运动规划和车辆控制方面。基于 DL 的 AVs 和 DL 技术通常存在许多缺点, 主要是数据集需要学习预测模型, 并且在累积误差的情况下无法自我校正。为了克服这些问题, 研究人员研究了其他技术, 如强化学习, 它可以在不需要收集数据的情况下从环境中学习。RL 使模型能够通过反复试验学习执行任务。

在本节中, 我们将介绍旨在解决 AVs 问题的现有基于 RL 的方法, 即 (1) 决策、(2) 运动规划、(3) 车辆控制和 (4) 自动驾驶汽车的社会行为。这些是自动驾驶中 RL 应用的主要领域。

### 5.1 决策

强化学习技术目前通过从经验和环境中学习，为 AVs 提供更好、更精确的信息。

[You 等人 \(2018 年\)](#) 提出了马尔可夫决策过程 (MDP) 来模拟飞行器与周围车辆之间的相互作用。MDP 通过考虑道路结构，允许 AVs 在超车或尾随其他车辆时做出适当的决定。然而，需要在不同的场景中进行更多的测试来验证他们的方法。

[Hoel 等人 \(2018 年\)](#) 提出了一种在公路上做出决策（如换道、加速和制动）的方法。他们利用深度 Q 网络 (DQN) 来训练他们的提议并预测正确的决策。然而，他们的方法不能保证在其他情况下（如环岛和交叉口）的安全。

无信号交叉口被认为是 AVs 做出准确及时决策的最具挑战性的场景之一。[Isele 等人 \(2018 年\)](#) 提出了一种基于 DQN 的方法，以安全地导航 AVs 通过交叉口。他们的提议的结果优于传统方法 ([Hafner 等人, 2013 年](#); [Alonso 等人, 2011 年](#))。

[Okuyama 等人 \(2018 年\)](#) 将 CNN 和 RL 结合起来，在模拟环境中使用车道标线和静态障碍物。CNN 拍摄 AVs 前摄像头拍摄的图像，以提取道路的主要状态特征。这些特征被馈送到 DQN 以预测动作。然而，他们的做法没有考虑到动态障碍。

[Hoel 等人 \(2019 年\)](#) 提出了一种战术决策方法，该方法结合蒙特卡洛树搜索 (MCTS) 和 RL 算法，在两种公路驾驶情况下（包括连续公路驾驶和驶离公路）驱动 AVs。他们的方案在模拟公路环境中进行了测试，初步结果显示了 RL 和 MCT 相结合的有效性。

[Hoel 等人 \(2020 年\)](#) 提出了另一种 AVs 战术决策方法，但采用了三车道单向公路。他们使用 RL 来估计驾驶过程中的动作，如加速、保持在车道上、左转、右转和刹车。结果表明，他们的方法随着时间的推移学会了做出有效的决策。

[Ye 等人 \(2019 年\)](#) 研究了一种 RL 方法，以允许 AVs 在单直车道（无信号控制）的道路上进行车道变换。该算法已在模拟环境中使用 Q 学习进行训练。然而，他们的提议需要在复杂场景中进行更多测试。

[Sun 等人 \(2020 年\)](#) 提出了一种使用 RL 的重型 AV 决策方法，即深度确定性策略梯度 (DDPG) 算法。网络接收 AVs 的信息状态（包括速度和与其他车辆的距离），然后做出决定。模拟结果表明，他们的方法能够从环境中快速做出决策。

[Duan 等人 \(2020 年\)](#) 提出了一种方法，用于训练 AVs 从环境中学习，根据 MDP 将决策分为三种机动（包括行车车道、右车道改变和左车道改变）。然而，他们只关注高速公路案例，而没有处理其他情况（如交叉口和城市交通）。

[Chen 等人 \(2019a\)](#) 提出了一种周围车辆密集的环形交叉口中的自动车辆定位系统的决策方法。他们的提案从每个周围物体的传感器（如速度和位置）获取信息。它使用 DQN 预测正确的操作。他们在卡拉模拟器中模拟了他们的算法，并显示了解决这种迂回情况的有希望的结果。

[Wolf 等人 \(2017 年\)](#) 使用 DQN 在模拟环境中训练 AVs。AVs 使用摄像头识别道路并采取转弯动作（例如，左、半左、直、半右和右）。然而，他们的提案需要考虑静态和动态障碍。

[Likmeta 等人 \(1035\)](#) 提出了三种情况下的决策方法（换车道、十字路口、环岛）。他们使用 RL 来训练 AV 学习在这些不同场景中做出决策。[Huang 等人 \(2019b\)](#) 通过考虑状态信息（如车速和道路距离），训练 AVs 使用 RL 采取行动（加速、减速和转向），以预测所需决策。

[Hu 等人 \(2019 年\)](#) 提出了一种使用 RL 融合两种场景的导航 AVs 决策方法。他们的方案在所有测试场景中都实现了零碰撞。然而,这种方法不能保证安全性,特别是在高机动性的真实交通中。

[Wang 等人 \(2020 年\)](#) 提出了一种在复杂公路交通中为 AVs 生成战术驾驶的方法。基于传感器信息(如车辆位置和速度),这些信息反馈给 DQN,以学习在高速公路情况下为每辆车做出决策(加速、减速、保持车道、右转和左转)。模拟结果表明,他们的方法提高了道路安全性。

## 5.2 动态规划

[Nosrati 等人 \(2018\)](#) 提出了一种基于 RL 的分层方法,使用 DQN 在多车道道路上驾驶 AVs。他们提案的目的是安全地避开障碍物(如其他车辆和/或摩托车)。这项工作仍需在复杂场景(如城市交通和交叉口)中进行测试。

[Paxton 等人 \(2017 年\)](#) 研究了蒙特卡洛树搜索(MCTS)方法,以使用 RL 生成长期运动规划任务。他们的方法主要是使自动车辆避免交叉口的碰撞。然而,他们的方案需要在其他复杂环境中进行更多测试。

[Zhu 等人 \(2018\)](#) 模拟了 AVs 与环境交互的学习过程。基于四个摄像头视图的数据,结果表明,RL 算法能够适应不同的交通状况。

[You 等人 \(2019 年\)](#) 考虑到道路几何,对 AVs 和公路交通之间的相互作用进行了建模。基于 Q-学习,AV 从其环境中学习行动(例如,车道移动、速度保持、加速和制动)。仿真结果表明,该方法能够适应其他车道和车辆较多的交通情况。

[Fayjie 等人 \(2018 年\)](#) 提出了一种运动规划方法,用于在两种情况下驾驶 AVs(包括城市交通和 5 车道公路)。他们使用 CNN 来提取来自摄像机和激光雷达的数据特征。这些特征被输入到 DQN 以估计右侧动作(例如,继续行驶、向左、向右、加速和制动)。然而,他们的提议没有考虑到其他道路参与者。

[Chen 等人 \(2020a\)](#) 提出了一种可解释的端到端方法,以生成复杂的城市场景(交叉口和环形交叉口)。RL 将摄像机和激光雷达的图像作为输入,避免密集交通中的碰撞。实验结果表明,该方法优于其他 RL 方法([Mnih 等人, 2015](#); [Lillicrap 等人, 2015 年](#); [Fujimoto 等人, 2018 年](#); [Haarnoja 等人, 2018](#))。

[Cao 等人 \(2020 年\)](#) 提出了一种用于 AVs 的 RL 公路退出规划方法。他们的建议允许根据环境观察估计离开公路的预期。他们的研究表明,高速公路出口成功率提高了 5%至 50%。

[Chen 等人 \(2020c\)](#) 使用 DQN 在整个环境中引导车辆。CNN 与 LSTM 一起用于从摄像机图像中提取状态信息。这些特征被输入到 DQN,以学习运动命令,如在十字路口直行、右转和左转。仿真结果表明,与 DDQN 方法相比,该方法学习速度更快([Wang 等人, 2016](#))。然而,他们的提案没有考虑到障碍物(如行人、骑自行车者和其他车辆)。

即使 DL 能够从专家驾驶员的停车数据中学习,人类知识也不能保证高效停车。为此,[Zhang 等人 \(2020a\)](#) 提出了一种 RL 方法,用于训练 AV 使用 MCT 学习停车策略。他们的建议实现了高效停车。

[Wang 等人 \(2020a\)](#) 提出了一种运动规划方法,该方法检测车辆轨迹中的障碍物,并使用 RL 自主避开障碍物。他们在多车道和不同交通密度的道路上训练进场。

[Lu 等人 \(2020 年\)](#) 使用 MDP 允许 AVs 处理复杂场景(包括没有交通信号的左转和多车道合并)。他们提案的目的是训练 AVs 在这两种情况下成功导航。实



验结果证明了该方法的有效性和效率。（文献详情见表 5）

表 5

年份	论文	神经网络	输出	算法	规划	脚本	实验
2017	Paxton	DQN&cDQN	避障	Adam	短期	十 字 路 口	Simulation
2018	Zhu	DQN	导航	SGD	适应	城市	Simulation
2018	Nosrati	DQN	避障	POM	短期	多车道	Simulation
2018	Fayjie	CNN	导 航 避 障	Mini-batch	适应	城 市 高 速	Simulation
2019	You	NN&DQN	换 挡 控 速	LSM	预测	高速	Simulation
2020	Chen	CNN&DQN	避障	AC	预测	交 叉 路 口	Simulation
2020	Cao	DQN	导航	Navigating	预测	高速	Simulation
2020	Chen	CNN&DQN	加速器	SA	长期	城市	Simulation
2020	Lu	DQN	实 现 左 转	Effectuating Left-turn	预测	交 叉 路 口	Simulation
2020	Wang	CNN	避障	Mini-batch	长期	交 叉 路 口	Simulation&Real
2020	Zhang	DNN	方向盘	BP	短期	停车场	Simulation&Real

### 5.3 车辆控制

RL 的目标是通过以迭代方式探索环境来找到最佳控制命令（例如，改变速度、制动或加速度）。环境会根据 AV 的当前行为奖励他们，以在未来纠正他们的错误。

*Li 等人 (2017)* 提出了一种控制多车道公路 AVs 的方法。他们训练他们的提案使用 RL 执行三个控制命令（减速、硬减速和维护）。

*Li 等人 (2019a)* 结合了两个模块，即感知和控制。感知模块将道路图像作为 CNN 的输入，以提取状态信息特征。这些特征被馈送到 DQN，以从环境中学习转向控制。他们的建议在不同的轨道上进行了测试，初步结果表明 AVs 学习到了有效的控制。

*Zhu 等人 (2020 年)* 提出了一种 RL 方法来控制 AVs 的速度，以使用深度确定性策略梯度 (DDPG) 快速避免碰撞 (*Lillicrap 等人, 2015 年*)。模拟结果表明，他们的方案在安全性和舒适性方面是有效的。

*Amini 等人 (2020 年)* 在不同天气条件（阳光和雨水）、白天（白天和晚上）和道路类型（农村和公路）下驾驶时，使用 RL 控制 AVs。AVs 观察物体（如树木、汽车和行人），并在路上避开它们。仿真结果证明了在真实道路上调整其方法的能力。

*Guo 等人 (2020 年)* 提出了一种三车道公路中基于 RL 的 AVs 横向控制策略。其方法的目标是安全地执行车道变换。结果表明，交通流量和通行能力有所改善。

*Wu 等人 (2020 年)* 研究了差分可变速度限制 (DVSL) 方法，以调节五车道高速公路中的 AVs 速度。DVSL 被建模为一个 MDP 问题，SUMO 模拟器用于训练 AVs 通过和 MDP 的交互进行学习。

[Chen 等人 \(2020b\)](#) 提出了一种使用蒙特卡洛树搜索 (MCTS) 方法的 RL, 用于 AVs 执行不同的机动, 以避免碰撞。他们将控制过程建模为 MDP 问题, 并使用 MCT 生成转向角。他们的建议显示出更稳定的控制和更高的成功率来避免意外事件。

[Zhang 等人 \(2018 年\)](#) 研究了一种基于 Van Hasselt 等人 2016 年使用的 DQN 和双 Q 学习控制 AVs 速度的方法。他们使用真实世界的数据对其提案进行了培训, 结果表明数值精度有所提高。

[Baheri 等人 \(2020 年\)](#) 提出了一种在城市驾驶中保持车道的方法。他们的方案从环境中提取状态测, 并使用 RL 在卡拉模拟器中训练 AVs。AVs 在两个城镇和不同天气条件下进行了模拟, 成功地完成了车道保持任务。

[Bouton 等人 \(2020 年\)](#) 利用 RL 和博弈论解决了密集交通中的机动问题。他们的方法被建模为 MDP 问题, 以允许 AV 在合并场景中保持或改变车道。结果表明, 与现有方法相比, 他们的建议能够更有效地学习。

[Ye 等人 \(2020 年\)](#) 提出了一种使用近端策略优化 (PPO) 和 RL 的高速公路自动车道变更策略。通过使用车辆和周围车辆的状态, AVs 学会避免碰撞并实现平滑机动。测试结果表明, 他们的方案有效且安全地学习了换道机动。

[Toromanoff 等人 \(2020 年\)](#) 提出了一种 RL 方法来解决复杂情况 (包括车道保持、行人和车辆避让)。他们使用卡拉模拟器来训练他们的模型, 只使用摄像机来识别城市驾驶。他们使用 DQN 训练 AV 从环境中学习如何处理以前的情况。仿真结果表明, 他们的方案可以推广到未知环境。

类似地, [Jaritz 等人 \(2018 年\)](#) 仅使用摄像机观察环境, 以学习根据 ([Mnih 等人, 2016 年](#)) 的 RL 架构估计控制命令 (转向、加速、制动)。他们讨论了不同道路结构 (如转弯和丘陵)、图形 (如季节和位置) 和物理 (如道路附着) 的轨道。然而, 他们提出的方法没有考虑碰撞。

[Wang 等人 \(2018 年\)](#) 研究了在一个方向上有三条车道的高速公路路段中 AVs 的车道变更控制。他们使用 Qlearning 生成车道变换, 同时考虑周围车辆的行为。实验表明, 他们的方法在学习车道变换方面取得了很好的效果。

[Liang 等人 \(2018 年\)](#) 提出了一种可控模拟 RL (CIRL) 方法, 使用 [Lillicrap 等人 \(2015 年\)](#) 中的 DDPG 和卡拉模拟器在混合场景 (汽车和行人) 中引导 AVs。他们的结果优于现有的 RL 技术 ([Dosovitskiy 等人, 2017 年](#))。(文献详情见表 6)




表 6

年份	论文	输出	RL	算法	场景	实验
2017	Li	减速	MDP	纵向&横向	多道高速	Simulation
2019	Li	掌舵	CNN&DDPG	横向	TORCS	Simulation&Real
2020	Zhu	控速	DDPG	纵向	主干道	Simulation
2020	Amini	掌舵	CNN	横向	乡村&高速	Simulation
2020	Guo	换道	DQN	横向	3 道高速	Simulation
2020	Wu	限速	DDPG	纵向&横向	城市交通	Simulation
2020	Chen	控速	CNN	横向	城市交通	Simulation
2018	Chen	掌舵	DQN	横向	城市交通	Real
2020	Baheri	加速	RNN	纵向&横向	高速	Simulation
2020	Toromaoff	变道	DQN	纵向&横向	城市交通	Simulation
2020	Ye	控速	NN	横向	城市交通	Simulation&Real
2020	Zhang	限速	DQN&Resnet	纵向&横向	城市交通	Simulation
2018	Jaritz	掌舵&转向 &手动档	CNN&LSTM	纵向&横向	有坡度的交 叉路口	Simulation
2018	Wang	变道	DQN	横向	城市交通	Simulation
2018	Liang	加速	DDPG	纵向&横向	城市交通	Simulations

#### 5.4 自动驾驶汽车的社会行为

任何建模系统都必须能够实时处理城市交通中的道路使用者行为。在这方面，RL 方法证明了 AVs 理解道路使用者行为并做出正确决策的能力。

[Saleh 等人 \(2018 年\)](#) 提出了城市交通环境中行人的意图预测问题。基于过去行人的轨迹观测，他们的建议允许使用 RNN 和 RL 技术预测未来行人的行为。结果表明，在预测方面有显著改进。

[Li 等人 \(2020a\)](#) 提出了一种 RL 方法来识别行人行为，并使用 MDP 避免行人行为。他们考虑了车辆和行人都位于结构化双车道道路上的情况。车辆沿着道路行驶，而行人正在等待横穿道路，这可能会导致事故。他们方法的目的是避免这种冲突。

[Li 等人 \(2020b\)](#) 研究了 RL 方法，以估计复杂场景中未来行人的位置。他们提案的目的是训练 AVs，使其学会识别道路上每个行人的未来姿势。在预测精度方面，他们的结果优于现有工作 ([Van den Berg 等人, 2008 年](#); [Chen 等人, 2017b](#); [Everett 等人, 2018 年](#); [Gupta 等人, 2018](#))。

[Nasernejad 等人 \(2021\)](#) 将十字路口行人和自动车辆之间的相互作用建模为 MDP 问题。他们的建议允许 AVs 根据行人在环境中的行为避开行人。然而，他们的方法仅限于行人和车辆的相互作用，而应考虑其他相互作用（如自行车和车辆）。

#### 六、开放的研究问题和未来方向

尽管基于深度学习和强化学习的技术在自动驾驶解决方案中取得了显著成果，但在全自动驾驶汽车上路之前，仍有许多挑战需要克服。在本节中，我们将讨论 DL 和 RL 用于 AV 的挑战、开放研究问题以及未来方向。

## 6.1 场景理解

AVs 面临的主要挑战是对复杂的现实世界有很好的理解。到目前为止, DL 方法在表征和识别交通环境中的对象方面表现出了显著的性能。然而, 我们目前的调查显示, 大多数已发表的论文并未解决 AVs 在各种交通类型、天气条件和照明条件下的问题。因此, 应进行进一步的研究以评估夜间在雪地和其他天气条件下驾驶的影响。此外, 仍然不能保证使用已知数据或其他收集的数据集训练神经网络是否足以让 AVs 理解所有可能的场景。也就是说, 就 AVs 将遇到的对象而言, 数据集是否完整?

该领域的大多数已发表论文使用 DL 技术, 尤其是 CNN, 来检测和识别环境中的对象。如果我们想将 RL 技术应用于场景理解和感知, 例如, 当 AVs 检测到物体时, 它们必须在训练期间纠正这个错误。有人可能会争辩说, 我们如何才能找到结果?

目前, 视频对象检测是 AVs 的一项关键挑战, 因为它是一项实时操作。仍然需要进一步改进视频对象检测。[Das 等人 \(2020 年\)](#) 和 [Liu 等人 \(2020 年\)](#) 准确率分别达到 90% 和 84.6%。然后, 应该通过使用更高效和有效的运动估计和特征提取网络来提高准确性。

在复杂的驾驶场景中实时感知行人位置是 AVs 相关研究中的另一个挑战。[Zhao 等人 \(2020\)](#) 提出了一个名为 P-LPN 的解决方案对在车道上移动或站在安全人行道上的行人进行分类, 然而这种方法仍然不足以让 AVs 了解行人的运动。进一步研究如何整合行人意图模型中的估计仍然是未来最重要的。

对于目标检测和分类, DL 的缺点之一是需要庞大的数据集。模型需要使用大量数据进行训练以消除任何最终的偏差。与人类的反应相比, AV 对情况的反应可能完全不同, 并且具有潜在的危险性。DL 方法总是使用相同的优化算法来调整神经网络的权重。因此, 它们需要先进的优化技术来获得可接受的结果。

AVs 检测道路上的行人以识别他们的意图, 基于这些意图, 自动驾驶汽车做出避开行人的决定。然而, 行人的运动是不可预测的, 有时很难估计他们的意图。AVs 该如何在困难情况下检测和识别行人行为? 有很多情况可能会导致意想不到的结果。例如, AVs 在隐藏红绿灯的情况下如何应对雪?

## 6.2 运动规划

在驾驶过程中, AVs 应该如何在复杂的城市交通中, 尤其是在十字路口和拥堵时段, 平稳安全地导航? 只有少数研究工作在现实世界中进行了测试, 大多数现有工作都是基于模拟来面对现实世界的测试。在模拟环境和实际部署中使用学习技术 (例如 DL 和 RL) 之间存在很大差距。此外, 目前的工作仅在特定的驾驶条件下进行了评估, 尚未在其他复杂场景中进行验证。

几种提出的方法使用 SUMO 来模拟 RL 模型, 但是 SUMO 仅限于 2D 模拟, 这使得它不适合真实世界的表示。此外, 大多数现有贡献都使用了旧版本的模拟器, 例如 Udacity 和 CARLA。因此, 未来的方法应该在提供新功能的最新版本中进行测试。例如, CARLA 的最后一个版本 0.9.13 允许在具有 3D 位置的模拟中包括行人 (包括成人和儿童)。这些新功能可以帮助研究人员使用更复杂的场景进行实验。

大多数提议的方法评估 AVs 是通过它们如何使用多个模拟器 (例如 Udacity、TORCS 和 CARLA) 在场景中安全导航。但是, 这些方法需要在现实生活场景中进行测试, 以检查它们在现实世界中是否保持其性能。



### 6.3 决策

在密集的交通中，由于所有道路使用者（其他车辆、自行车和行人）的高机动性，AVs 几乎总是很难做出正确的驾驶决定。DL 和 RL 技术在处理此类情况方面显示出有希望的结果。然而，更复杂的场景（如十字路口和人行横道）仍有待研究。

现有的决策方法通常使用监督学习技术来模拟人类驾驶，这些方法并没有涵盖所有可能的驾驶场景。对于每个国家不同的驾驶情景，收集所有必要的信息极其困难。此外，研究人员必须解决两个主要目标，即他们提出的方法的鲁棒性和灵活性，这允许 AVs 在没有先验知识的情况下处理任何情况。

有许多意外事件需要研究人员进一步调查。例如，AV 可能决定加速，因为道路上没有碰撞。然而，行人可能同时突然过马路。这导致我们询问自动驾驶汽车如何避开这个行人。那么 DL 和 RL 如何处理这种情况？

所研究的方法部署了 DL 和 RL 技术来训练 AVs 以从其环境（例如，高速公路、交通和十字路口）中学习。但是，我们注意到三个未解决的主要问题，即：

- 1) 大多数方法没有考虑其他道路使用者（例如行人和骑自行车的人）。
- 2) 几乎所有使用的技术都没有处理不同的天气和光照条件（例如，雪和夜晚）。
- 3) 自动驾驶汽车经过培训可以从模拟环境中学习，但应该在现实世界中对其进行测试以确认其能力。

### 6.4 车辆控制

AVs 控制的作用是纠正运动规划和决策任务产生的任何最终错误，构建实时纠正错误的控制系统仍然是一个挑战。一个开放的研究领域给出了所有道路使用者的运动规划，AVs 应该如何管理速度以避免事故。

车辆控制系统的主要挑战是开发处理不同环境的方法。例如，城市交通中成功的控制策略可能不适用于具有不同交通特性和安全问题的高速公路。

在良好的天气条件下测试了几种方法，但这些方法不足以实现 AVs 的安全性。例如，晴天控制速度或刹车与下雪天不同；有必要涵盖所有潜在条件以验证这些方法的效率。

RL 的主要目标是最大化奖励，大多数提出的方法使用大量的负奖励来避免不希望的行为。然而，随意选择这些奖励并不能有效地处理道路上的最终碰撞。由于这些原因，有必要使用基于周围车辆的速度和位置和其他参数的数学方程来选择奖励。例如，[Knox 等人 \(2021\)](#) 解决自动驾驶中的奖励设计问题，并提出一些解决方案来帮助研究人员构建奖励。

### 6.5 自动驾驶汽车的社会行为

自动驾驶最困难的任务是了解其他道路使用者的意图。例如，行人是最脆弱的道路使用者，因为了解他们的行为并不直观，并且取决于各种因素。因此，快速预测未来行人的位置仍然是 AVs 系统面临的挑战。

DL 和 RL 展示了它们在环境中识别物体和避开它们的性能，但是要开发有效的方法来实时估计行人或其他道路参与者的意图，还有很多工作要做。尤其是在具有高机动性的情况下（例如，十字路口、环形交叉路口和人行横道）。

大多数研究人员通过仅保护行人而忽略其他道路使用者（例如摩托车和骑自

行车者)来限制他们的研究,而统计数据显示,这些道路参与者中有大量死于事故。

一个可能还会被问到的问题是 AVs 将应该如何与人类驱动交互?这个问题应该考虑因为在可预见的将来,人为驱动的卡片将继续出现在所有道路上。

当 AVs 检测到行人时,这些方法不应该只关注检测行人,还要了解他们的动作和意图。如果行人过马路时是否集中,建议的方法应识别行人是儿童、成人还是老人,因为每个人都有自己的过马路方式。

## 6.6 通信

通信的作用对于填补传感器限制的空白和更多地了解道路参与者的运动是必要的。然而,该领域的主要挑战是如何利用 DL 和/或 RL 技术实时处理来自 V2V 和 V2I 的大数据流,然后在几秒钟内做出决策。

人类驾驶员可以使用标志(例如眼神交流)与行人交流,这在 AVs 的情况下是不可能的。重要的是在未来解决这个问题,以确保对 AVs 更有信心。

此外,V2V 通信仍然不能保证 AVs 将在车辆之间进行可靠传输。某些 AVs 可能会错过共享消息。因此,问题是如何构建可靠的 AVs,即使在错过共享道路信息的情况下也能安全驾驶。

AVs 可以从其他车辆收集道路信息,因此它增加了它们在 DL 过程中的训练过程。然后,V2V 应该快速且稳健地共享这些信息,以帮助其他车辆感知环境。

开发基于深度学习的协同自动驾驶框架还有很多工作要做,这可以有效提高学习准确率,降低环境感知和内容共享的成本。

## 七、结论

在过去的十年中,随着实现车辆完全自主的驱动,自动驾驶汽车的研究越来越受到关注。在我们的道路上引入自动驾驶汽车的目的是超越驾驶员辅助技术,使车辆能够在没有人为干预的情况下自行驾驶。自动驾驶汽车可以显著减少与汽车相关的死亡和伤害,并解决各种长期存在的交通挑战,即道路拥堵、旅行延误、停车和安全。智能交通系统、计算系统和人工智能的最新进展刺激并为自动驾驶汽车的发展铺平了道路。这为智能道路、智能交通安全和出行者舒适度开辟了新机遇。

很少有研究关注 DL 和 RL 技术在解决与场景理解、运动规划、决策、车辆控制、社会行为和通信相关的 AVs 挑战方面的作用。

在本文中,我们调查了有关正在进行的研究工作的文献,旨在使用 DL 和 RL 技术解决主要的 AV 问题。我们介绍了迄今为止已用于为自动驾驶的四个主要问题提供解决方案的主要 DL 和 RL 工作的分类。

我们阐明了 DL 和 RL 方法在自动驾驶汽车不同方面的潜力,并强调了在该领域可以实现的目标。我们还讨论了 DL 和 RL 在自动驾驶方面带来的改进,这些改进可以克服传统 ML 技术的局限性。

最后,我们指出了现有的主要研究挑战,并确定了开发全自动自动驾驶汽车未来可能的研究方向。我们相信,我们的调查将作为未来自动驾驶汽车研究计划的指南。